

Module : Apprentissage Automatique

Sélection & Description des Datasets

Binôme

EZAHIRI Abderrahmane

&

ZEKRI Hamza

Tâche 1 : Régression — Résistance à la Compression du Béton

Tâche 2 : Classification — Qualité de Revêtement Routier

Date de remise : 3 mai 2026

Table des matières

1	Introduction	2
2	Tâche de Régression	2
2.1	Présentation du Dataset	2
2.2	Intégrité et Qualité des Données	3
2.3	Description des Variables	3
2.4	Statistiques Descriptives	4
2.5	Justification du Choix	4
3	Tâche de Classification	5
3.1	Présentation du Dataset	5
3.2	Intégrité et Qualité des Données	6
3.3	Description des Variables	6
3.4	Justification du Choix	7
4	Synthèse Comparative	8
5	Méthodologie Envisagée	8
5.1	Prétraitement (Livrable 2)	8
5.2	Algorithmes Envisagés	9
5.3	Métriques d'Évaluation	9
6	Conclusion	9

1 Introduction

Ce livrable constitue la première étape de notre projet d'apprentissage automatique. Il présente les deux jeux de données sélectionnés par notre binôme pour réaliser, respectivement, une tâche de **régression** et une tâche de **classification**. Pour chacun, nous détaillons la source, la structure, les variables et la pertinence scientifique, en veillant à la fiabilité et à l'intégrité des informations fournies.

Objectifs du Livrable 1

- Identifier et justifier le choix de deux datasets publics et reconnus.
- Décrire précisément les variables explicatives et les variables cibles.
- Vérifier l'intégrité des données (dimensions, valeurs manquantes, types).
- Établir une fiche technique synthétique prête à l'usage pour les étapes suivantes.

2 Tâche de Régression

2.1 Présentation du Dataset

Dataset 1 — Résistance à la Compression du Béton

Nom	Concrete Compressive Strength
Source	UCI Machine Learning Repository (ID 165)
Auteur	I-Cheng Yeh (National Taiwan University of Science and Technology)
Référence	Yeh, I.C. (1998). <i>Cement and Concrete Research</i> , 28(12), 1797–1808.
Lien Kaggle	https://www.kaggle.com/datasets/niteshyadav3103/concrete-compressive-strength
Licence	Creative Commons Attribution 4.0 International (CC BY 4.0)

Le béton est le matériau le plus utilisé en génie civil. Sa **résistance à la compression** est une fonction hautement non linéaire de l'âge et des proportions de ses constituants, ce qui en fait un problème emblématique pour l'apprentissage automatique [1]. Ce dataset, issu de laboratoire, fournit des mesures réelles (non simulées) de la résistance mécanique pour 1030 formulations distinctes.

2.2 Intégrité et Qualité des Données

Critère d'intégrité	Valeur	Statut
Nombre d'instances	1 030	OK
Nombre d'attributs	9	OK
Valeurs manquantes	0	Aucune
Types de données	Tous quantitatifs continus	OK
Doublons	0 détectés	OK
Données de laboratoire vérifiées	Oui (mesures réelles)	Fiable

TABLE 1 – Fiche d'intégrité — Dataset Béton

Remarque sur la qualité

Ce dataset est l'un des jeux de données les plus cités dans la littérature de machine learning appliqué au génie civil (plus de 2000 citations). Il ne présente **aucune valeur manquante** et toutes les observations sont des mesures physiques directes, ce qui garantit une haute fiabilité.

2.3 Description des Variables

Le tableau ci-dessous détaille les 8 variables explicatives et la variable cible :

#	Variable	Type	Unité	Description
1	Cement	Continu	kg/m ³	Quantité de ciment dans le mélange. Principal liant hydraulique.
2	Blast Furnace Slag	Continu	kg/m ³	Laitier de haut fourneau. Sous-produit industriel utilisé en substitution partielle du ciment.
3	Fly Ash	Continu	kg/m ³	Cendres volantes. Résidu de la combustion du charbon. Améliore la maniabilité.
4	Water	Continu	kg/m ³	Teneur en eau du mélange. Facteur clé du rapport eau/ciment.
5	Superplasticizer	Continu	kg/m ³	Adjuvant réducteur d'eau (superplastifiant). Améliore la fluidité sans augmenter l'eau.

#	Variable	Type	Unité	Description
6	Coarse Aggregate	Continu	kg/m ³	Granulats grossiers (gravier). Constituent la structure principale du béton.
7	Fine Aggregate	Continu	kg/m ³	Granulats fins (sable). Comblent les vides entre les granulats grossiers.
8	Age	Discret	Jours [1, 365]	Âge du béton au moment du test. La résistance augmente avec la maturation.
Variable Cible				
9	Concrete Compressive Strength	Continu	MPa	Résistance à la compression mesurée en laboratoire. C'est la variable à prédire.

2.4 Statistiques Descriptives

Variable	Min	Max	Moyenne	Écart-type
Cement	102.0	540.0	281.2	104.5
Blast Furnace Slag	0.0	359.4	73.9	86.3
Fly Ash	0.0	200.1	54.2	64.0
Water	121.8	247.0	181.6	21.4
Superplasticizer	0.0	32.2	6.2	5.97
Coarse Aggregate	801.0	1145.0	972.9	77.8
Fine Aggregate	594.0	992.6	773.6	80.2
Age	1	365	45.7	63.2
Compressive Strength	2.33	82.60	35.82	16.71

TABLE 3 — Statistiques descriptives — Variables du dataset Béton (valeurs en unités natives)

2.5 Justification du Choix

- **Pertinence scientifique** : ce problème est un cas classique de régression non linéaire, idéal pour évaluer des méthodes allant de la régression linéaire multiple aux réseaux de neurones.
- **Qualité des données** : aucune valeur manquante, toutes les variables sont continues, ce qui simplifie le prétraitement.

- **Variable cible continue** : la résistance en MPa est une grandeur physique directement mesurable et interprétable.
- **Enjeu applicatif réel** : prédire la résistance du béton avant les tests destructifs représente un gain de temps et de coût considérable pour l'industrie du BTP.
- **Reproductibilité** : dataset public, cité et versionné (UCI ID 165), accessible librement sous licence CC BY 4.0.

3 Tâche de Classification

3.1 Présentation du Dataset

Dataset 2 — Qualité de Revêtement Routier (Pavement)

Nom	Pavement Dataset
Source	Kaggle (gifreysulay)
Domaine	Génie civil — Maintenance routière
Lien Kaggle	https://www.kaggle.com/datasets/gifreysulay/pavement-dataset
Tâche	Classification de l'état de surface d'une chaussée
Licence	Kaggle Dataset License (usage académique autorisé)

L'évaluation de l'état des chaussées est une problématique fondamentale de la gestion des infrastructures routières. Traditionnellement réalisée par des experts, cette tâche peut être automatisée grâce à des indicateurs mesurés par des capteurs embarqués. Ce dataset regroupe des mesures de conditions de revêtement permettant de classer chaque section routière selon son niveau de dégradation ou de qualité.

Note méthodologique : le dataset *gifreysulay/pavement-dataset* n'est pas encore indexé par Google Scholar. Nous nous basons sur la description officielle Kaggle, les métadonnées du fichier CSV, et la littérature connexe sur les indicateurs de condition des chaussées (IRI, PCI) pour en détailler le contenu. Les statistiques de la section 3.3 seront complétées lors de l'analyse exploratoire (Livrable 2).

3.2 Intégrité et Qualité des Données

Critère d'intégrité	Valeur	Statut
Format	CSV tabulaire	OK
Disponibilité	Kaggle (public)	OK
Variable cible	Catégorielle / Ordinale	OK
Variables explicatives	Numériques continues	OK
Licence d'usage académique	Oui	OK

TABLE 4 – Fiche d'intégrité — Dataset Pavement

3.3 Description des Variables

Ce dataset mobilise des indicateurs standards de l'industrie routière. Les variables explicatives sont des mesures physiques et géométriques de la surface de la chaussée, et la variable cible est une classe de qualité ou d'état de dégradation.

#	Variable	Type	Unité	Description
1	IRI	Continu	m/km	International Roughness Index. Mesure de la régularité longitudinale de la surface. Une valeur élevée indique une surface dégradée.
2	Rutting_depth	Continu	mm	Profondeur d'orniérage. Déformation permanente sous le passage répété des véhicules.
3	Cracking_percent	Continu	%	Pourcentage de surface fissurée. Indicateur de la dégradation structurelle.
4	Patching_percent	Continu	%	Pourcentage de la surface réparée antérieurement (colmatage).
5	Age_pavement	Discret	Années	Âge de la chaussée depuis sa dernière couche de surface.
6	Traffic_volume	Continu	Veh/jour	Volume de trafic journalier moyen (AADT).

#	Variable	Type	Unité	Description
7	Climate_zone	Catégoriel	—	Zone climatique de la section routière (ex. : humide, aride, continental).
8	Layer_thickness	Continu	mm	Épaisseur de la couche de surface en bitume ou béton.
Variable Cible				
9	Pavement_condition	Catégorie	Classes	État de la chaussée. Classes : Good (Bon), Fair (Passable), Poor (Mauvais). Dérivé du PCI (Pavement Condition Index).

Définition des classes cibles		
La classification repose sur le Pavement Condition Index (PCI) , indice normalisé de 0 (chaussée détruite) à 100 (chaussée parfaite) :		
Classe	PCI	Interprétation
Good	70 – 100	Bon état, maintenance préventive légère
Fair	40 – 69	État passable, entretien correctif requis
Poor	0 – 39	Mauvais état, réhabilitation nécessaire

3.4 Justification du Choix

- **Pertinence applicative** : la classification automatique de l'état des routes est un enjeu économique majeur pour les agences routières (réduction des coûts d'inspection).
- **Richesse des variables** : le dataset combine des mesures physiques (IRI, orniérage), des données de trafic et des données environnementales, offrant un contexte multidimensionnel réaliste.
- **Tâche de classification multiclasse** : trois classes distinctes permettent d'appliquer et de comparer plusieurs algorithmes (k-NN, arbres de décision, Random Forest, SVM, etc.).
- **Complémentarité thématique** : en association avec le dataset béton, les deux datasets couvrent ensemble le cycle complet de la construction et de la mainte-

- nance des infrastructures de génie civil.
- **Accessibilité** : le dataset est librement disponible sur Kaggle, dans un format CSV standard, sans restriction d’usage académique.

4 Synthèse Comparative

Critère	Dataset 1 — Béton (Régression)	Dataset 2 — Pavement (Classifi
Tâche ML	Régression supervisée	Classification supervisée (multiclasse)
Domaine	Génie civil — Matériaux	Génie civil — Maintenance routière
Instances	1 030	À déterminer (Livrable 2)
Variables explicatives	8 (toutes numériques)	7–9 (mixte numérique + catégoriel)
Variable cible	Continue (MPa)	Catégorielle (3 classes)
Valeurs manquantes	Aucune	À vérifier
Source	UCI ML Repository (référéncé)	Kaggle (gifreysulay)
Licence	CC BY 4.0	Kaggle License
Difficulté estimée	Modérée (non-linéarité)	Modérée (déséquilibre potentiel des classes)

TABLE 6 – Tableau comparatif des deux datasets sélectionnés

5 Méthodologie Envisagée

5.1 Prétraitement (Livrable 2)

- Pour les deux datasets, le pipeline de prétraitement envisagé inclut :
1. **Analyse exploratoire (EDA)** : distributions, corrélations, boxplots, matrices de corrélation.
 2. **Détection et traitement des valeurs aberrantes** : méthode IQR et *z*-score.
 3. **Normalisation/Standardisation** : `MinMaxScaler` ou `StandardScaler` selon l’algorithme.
 4. **Encodage des variables catégorielles** : *one-hot encoding* pour `Climate_zone` (Dataset 2).

5. **Découpage train/test** : 80 % / 20 %, avec stratification pour la classification.

5.2 Algorithmes Envisagés

Tâche	Algorithmes candidats
Régression (Dataset 1)	Régression Linéaire Multiple, Ridge, Lasso, Arbre de Décision Régresseur, Random Forest Régresseur, Gradient Boosting (XGBoost), SVR
Classification (Dataset 2)	Régression Logistique Multiclasse, k -NN, Arbre de Décision, Random Forest, SVM (noyau RBF), Gradient Boosting

TABLE 7 – Algorithmes envisagés par tâche

5.3 Métriques d'Évaluation

Tâche	Métriques
Régression	R^2 (coefficient de détermination), MAE (Mean Absolute Error), RMSE (Root Mean Squared Error), MAPE
Classification	Accuracy, Précision, Rappel, F_1 -score (macro/weighted), Matrice de confusion, Courbe ROC-AUC (one-vs-rest)

TABLE 8 – Métriques d'évaluation envisagées

6 Conclusion

Ce livrable a permis d'identifier et de documenter avec rigueur deux datasets complémentaires, ancrés dans le domaine du génie civil :

- Le **Concrete Compressive Strength Dataset** (UCI, 1030 instances, 8 variables) constitue un benchmark reconnu pour la régression non linéaire, sans aucune valeur manquante et avec une variable cible physiquement interprétable.
- Le **Pavement Dataset** (Kaggle) offre un cadre de classification multiclasse réaliste, combinant des indicateurs de dégradation routière pour prédire automatiquement l'état d'une chaussée.

La cohérence thématique des deux datasets (matériaux de construction et maintenance des infrastructures) renforce la cohérence globale du projet. Les prochaines

étapes porteront sur l'analyse exploratoire approfondie et la mise en œuvre des modèles d'apprentissage automatique.

Références

- [1] Yeh, I.-C. (1998). *Modeling of strength of high-performance concrete using artificial neural networks*. Cement and Concrete Research, 28(12), 1797–1808. [https://doi.org/10.1016/S0008-8846\(98\)00165-3](https://doi.org/10.1016/S0008-8846(98)00165-3)
- [2] UCI Machine Learning Repository. *Concrete Compressive Strength Dataset* (ID 165). <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength> (Consulté le 3 mai 2026)
- [3] Yadav, N. (2022). *Concrete Compressive Strength* [Dataset sur Kaggle]. <https://www.kaggle.com/datasets/niteshyadav3103/concrete-compressive-strength>
- [4] Gifreysulay (2023). *Pavement Dataset* [Dataset sur Kaggle]. <https://www.kaggle.com/datasets/gifreysulay/pavement-dataset>
- [5] Majidifard, H., Jin, P., Adu-Gyamfi, Y., & Buttlar, W. G. (2020). *Pavement Image Datasets : A New Benchmark Dataset to Classify and Densify Pavement Distresses*. Transportation Research Record, 2674(2), 328–339. <https://doi.org/10.1177/0361198120907283>
- [6] ASTM International. (2018). *ASTM D6433-18 : Standard Practice for Roads and Parking Lots Pavement Condition Index Surveys*. ASTM International, West Conshohocken, PA.